

ТЕХНИЧЕСКИЙ ОТЧЁТ: Развертывание AI-платформы AstraChat

«Развертывание гетерогенной микросервисной архитектуры и интеграция локальных ядер инференса в ИС AstraChat AI System»

Цель этапа: Локальное развертывание, адаптация под CPU-вычисления, устранение конфликтов безопасности и интеграция пула больших языковых моделей (LLM) в изолированный контур платформы.

1. Аппаратная спецификация и оптимизация хост-платформы

- **Вычислительный узел:** Ноутбук Lenovo ThinkPad E14 Gen 5 на базе процессора AMD Ryzen (архитектура x86_64, инструкции AVX2/FMA3).
- **Оптимизация подсистемы памяти:** Физический объем ОЗУ адаптирован под пиковые ML-нагрузки путем развертывания подсистемы виртуальной подкачки zram (8 ГБ, алгоритм сжатия `lzo-rle`) в связке с SWAP-разделом (17.7 ГБ) для предотвращения аварийных завершений процессов по триггеру *Out-Of-Memory* (OOM).
- **Перераспределение дискового пространства:** Корневая директория хранения Docker-образов перенесена на емкий домашний раздел (`/home`) хост-системы для обеспечения сохранности ~11 ГБ весов локальных нейросетей.

2. Модификация Docker-архитектуры под CPU-инференс

- **Исключение CUDA-зависимостей:** Из манифеста `docker-compose-llm-svc.yml` полностью вырезана аппаратная привязка к проприетарной архитектуре NVIDIA CUDA (секция `devices`, драйверы, переменные окружения `CUDA_VISIBLE_DEVICES` и `NVIDIA_VISIBLE_DEVICES`). Сервис инференса `llm-svc` успешно переведен в кроссплатформенный режим выполнения на центральном процессоре с использованием библиотек векторизации.
- **Конвейерная сборка микросервисов:** Для обхода ограничений кэша компилятора BuildKit применен пошаговый конвейерный запуск (базы данных → бэкенд → фронтенд → AI-модули) с сопутствующей очисткой промежуточных слоев через `docker builder prune`.

3. Разрешение конфликтов сетевой и системной безопасности

- **Укрощение SELinux (Fedora Workstation):** Устранены блокировки доступа контейнеров к смонтированным директориям хоста. Для рабочих папок проекта

и каталога локальных весов моделей принудительно изменен контекст безопасности файловой системы на `svirt_sandbox_file_t`.

- **Исправление сетевой топологии Docker:** Устранена сетевая изоляция между независимыми YAML-файлами конфигураций. Внутри общего изоляционного моста `astrachat-network` для контейнера `llm-svc` настроен сетевой псевдоним (`alias`) `llm-service`, что восстановило DNS-резолвинг для графовых маршрутов оркестратора `svc-rag`.
- **Авторизация и сброс ограничений СУБД:** В файле переменных окружения `.env` настроена строгая `root`-авторизация для СУБД **MongoDB**. Осуществлено прямое подключение к базе данных `astrachat` через утилиту `mongosh`, в ходе которого сброшены битые сессионные лимиты контекстного окна.

4. Интеграция и верификация пула локальных моделей

С помощью современной CLI-утилиты `hf` в локальный каталог `models/` интегрированы и успешно выведены во фронтенд две модели в формате GGUF:

1. **Qwen3.5-9B-q4_k_m.gguf** (Универсальная, 5.63 ГБ).
2. **qwen2.5-coder-7b-instruct-q5_k_m.gguf** (Специализированная, 5.44 ГБ).

Результаты верификации (Сравнительный анализ):

- **Qwen3.5-9B:** Продемонстрировала нестабильность при инференсе на CPU. При обработке сложных контекстных инструкций и переключении языковых токенов вызывает аппаратный сбой сегментации памяти **Signal: 11 (SEGV)** внутри бинарной библиотеки `libggml-cpu.so`, что приводит к падению процесса `uvicorn` и разрыву соединения (`incomplete chunked read`).
- **Qwen2.5-Coder-7B (Q5_K_M):** Продемонстрировала **абсолютную стабильность** выполнения. Модель детерминированно обрабатывает системные промпты, не расходует ресурсы процессора на скрытые англоязычные рассуждения (Thinking Process) и успешно генерирует чистую Markdown-структуру презентации слайд за слайдом напрямую на русском языке.

Текущий статус проекта: Архитектура полностью работоспособна, пул моделей активен в ОЗУ, веб-интерфейс доступен на порту `3000`. Система готова к интеграции выделенного файлового **MCP-сервера** для прямой сборки `.pptx` файлов на диске.

Все чаты

Сегодня

Последние 7 дней

Вы18:46

напиши структуру для небольшой презентации (3-4 слайда) на тему Обучение ИИ

AstraChat18:48

Конечно! Вот пример структуры для презентации на тему "Обучение ИИ" на три или четыре слайда:

Слайд 1: Введение

- **Заголовок:** Обучение ИИ
- **Подзаголовок:** Что такое ИИ и как она обучается?
- **Текст:**
- **ИИ - это область искусственного интеллекта, которая позволяет компьютерам "учиться" и улучшать свои алгоритмы без явного программирования.**
- **Методы обучения ИИ:** машинное обучение, генетический алгоритм, обратное распространение ошибок.

Слайд 2: Методы обучения ИИ

- **Заголовок:** Методы обучения ИИ
- **Текст:**
- **Машинное обучение:** Компьютеры учатся на основе данных. Методы: обучающие, валидирующие и тестовые наборы.

- **Генетический алгоритм:** Используется для поиска оптимальных решений. Аналогия с естественным отбором.
- **Обратное распространение ошибок:** Используется в нейронных сетях для обучения.

Слайд 3: Применение ИИ в различных сферах

- **Заголовок:** Применение ИИ
- **Текст:**
- **Healthcare:** Анализ медицинских данных, диагностика болезней, рекомендации по лечению.
- **Finance:** Обнаружение мошенничества, анализ рынка, прогнозирование финансовых индикаторов.
- **Transport:** Автомобили, управление парками, робототехника.
- **Retail:** Рекомендательные системы, оптимизация логистики, анализ покупательских данных.

Слайд 4: Итоги и перспективы

- **Заголовок:** Итоги и перспективы
- **Текст:**
- **ИИ становится всё более важной частью нашего общества и бизнеса.**
- **Огромный потенциал для улучшения качества**

Вы10:58

придумай сквозное оформление и для каждого слайда особенное

AstraChat11:00

Конечно! Вот пример сквозного оформления и уникальных дизайнерских элементов для каждого слайда в презентации на тему "Обучение ИИ":

Общее оформление:

- Цветовая палитра: Синий (глубокий) и белый (или светлый). Синий будет использоваться для заголовков и акцентов, белый для основного текста.
- Шрифт: Sans-serif (например, Arial, Helvetica) для основного текста, serif (например, Times New Roman) для заголовков.
- Фон: Светлый серый или белый фон, чтобы текст был хорошо читаемым.
- Изображения: Использование иллюстраций и иконок, связанных с ИИ, для визуализации.

Слайд 1: Введение

- Фон: Цветной фон (синий) с изображением AI-лица или мозга в белом.
- Заголовок: "Обучение ИИ" - крупный, белый шрифт (Arial), жирный стиль.
- Подзаголовок: "Что такое ИИ и как она обучается?" - белый шрифт (Arial), наклонный стиль.
- Текст: Обычный шрифт (Arial), размер 12pt.

Слайд 2: Методы обучения ИИ

- Фон: Цветной фон (синий) с изображением нейронной сети или генетического алгоритма в белом.
- Заголовок: "Методы обучения ИИ" - крупный, белый шрифт (Arial), жирный стиль.
- Текст: Обычный шрифт (Arial), размер 12pt. Использование списков с маркерами (например, ★, ▲, □) для выделения ключевых пунктов.

Слайд 3: Применение ИИ в различных сферах

- Фон: Цветной фон (синий) с изображением бизнес-диаграммы или карты мира в белом.
- Заголовок: "

Вы11:13

напиши код python для формирования Слайда 1

AstraChat11:15

Конечно! Вот пример кода на Python, который можно использовать для создания первого слайда в презентации с использованием библиотеки `python-pptx`. Этот код создаст слайд с заголовком и подзаголовком, используя предоставленные вами стили.

PYTHON

```
from pptx import Presentation

from pptx.util import Inches

from pptx.dml.color import RGBColor


# Создаем новую презентацию

prs = Presentation()


# Добавляем первый слайд с шаблоном "Title and Content"

slide_layout = prs.slide_layouts[1] # 1 - это индекс шаблона
"Title and Content"

slide = prs.slides.add_slide(slide_layout)


# Получаем элементы слайда
```

```
title = slide.shapes.title
```

```
subtitle = slide.placeholders[1]
```

```
# Устанавливаем стиль и содержимое заголовка
```

```
title.text = "Обучение ИИ"
```

```
title.text_frame.paragraphs[0].font.name = "Arial"
```

```
title.text_frame.paragraphs[0].font.size = Inches(1.5)
```

```
title.text_frame.paragraphs[0].font.bold = True
```

```
title.text_frame.paragraphs[0].font.color.rgb = RGBColor(255, 255,  
255) # Белый цвет
```

```
# Устанавливаем стиль и содержимое подзаголовка
```

```
subtitle.text = "Что такое ИИ и как она обучается?"
```

```
subtitle.text_frame.paragraphs[0].font.name = "Arial"
```

```
subtitle.text_frame.paragraphs[0].font.size = Inches(1)
```

```
subtitle.text_frame.paragraphs[0].font.italic = True
```

```
subtitle.text_frame.paragraphs[0].font.color.rgb = RGBColor(255,  
255, 255) # Белый цвет
```

```
# Устанавливаем фон слайда
```

```
slide.background.fill.solid()
```

```
slide.background.fill.fore_color.rgb = RGBColor(0, 0, 139) #
```

Темный синий цвет

```
# Сохраняем презентацию
```

```
prs.save('obuchenie_ii.pptx')
```

Этот код создаст презентацию с одним слайдом, который включает заголовок "Обучение ИИ" и подзаголовок "Ч

Вы11:25

проверь так ли получилось как ты задумывал?

AstraChat11:27

Извините, но я не могу проверить или взглянуть на прикрепленный документ, так как я являюсь текстовым ассистентом и не могу работать с файлами. Могу помочь только с текстовыми запросами и ответами.

Вы11:50

напиши код презентации в формате Markdown

AstraChat11:53

Конечно! Вот пример презентации в формате Markdown. Этот формат не поддерживает сложный дизайн и оформление, но он позволяет создать базовую структуру для презентации.

MARKDOWN

```
# Обучение ИИ
```


Что такое ИИ и как она обучается?

Методы обучения ИИ

- ****Машинное обучение****: Компьютеры учатся на основе данных.

Методы: обучающие, валидирующие и тестовые наборы.

- ****Генетический алгоритм****: Используется для поиска оптимальных решений. Аналогия с естественным отбором.

- ****Обратное распространение ошибок****: Используется в нейронных сетях для обучения.

Применение ИИ в различных сферах

- ****Healthcare****: Анализ медицинских данных, диагностика болезней, рекомендации по лечению.

- ****Finance****: Обнаружение мошенничества, анализ рынка, прогнозирование финансовых индикаторов.

- ****Transport****: Автомобили, управление парками, робототехника.

- ****Retail****: Рекомендательные системы, оптимизация логистики, анализ покупательских данных.

Итоги и перспективы

- ИИ становится всё более важной частью нашего общества и бизнеса.

- Огромный потенциал для улучшения качества жизни и эффективности бизнеса.

Этот код создает структуру для презентации с заголовками, подзаголовками и списками. Вы можете форматировать текст и добавлять изображения, если ваш Markdown редактор поддерживает это.

Вы13:55

TEXT

Markdown

проверь с начала чата, ты забыл поле текст

AstraChat13:57

На основе предоставленных результатов инструментов, мне удалось выявить следующую информацию:

Инструмент **enhance_prompt** завершился с ошибкой: "Инструмент 'enhance_prompt' неактивен". Это означает, что функционал, который должен был улучшить ваш запрос, недоступен в данный момент.

Инструменты для поиска информации в документах

(**retrieve_rag_context** / **search_documents**) не обнаружили релевантной информации. Это может быть связано с тем, что запрос не содержит ключевых слов или фраз, которые позволяют найти соответствующий контент в документах.

В связи с этим, я не могу предоставить полный и понятный ответ на ваш запрос. С учетом ошибки инструмента **enhance_prompt**, я не могу улучшить ваш запрос для поиска информации. Также, поскольку инструменты для поиска информации не нашли релевантной информации, я не могу использовать содержание документов для формирования ответа.

Если у вас есть конкретные вопросы или запросы, которые я могу помочь, пожалуйста, уточните их, и я постараюсь ответить наилучшим образом.